



FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

GLOBAL SOLUTION

GRUPO BLUEGATHER

Gustavo Sanches - RM 97068

Kaue Caponero - RM 96466

Mariana Santos - RM 97503

Natan Cruz - RM 97324

Vitor Rubim - RM 97092

São Paulo - SP

2024

SUMÁRIO

1. Apresentação da Equipe.....	3
2. Código Fonte do Projeto.....	3
3. Escopo do Projeto.....	3
4. Desafio 01.....	3
a. Descrição do Problema.....	3
b. Metodologia Utilizada.....	4
c. Resultados Obtidos.....	4
d. Conclusão.....	5
5. Desafio 02.....	6
a. Descrição do Problema.....	6
b. Metodologia Utilizada.....	6
c. Resultados Obtidos.....	7
d. Conclusão.....	7
6. Desafio 03.....	7
a. Descrição do Problema.....	7
b. Metodologia Utilizada.....	8
c. Etapas de Desenvolvimento.....	8
d. Resultados Obtidos.....	9
e. Conclusão.....	9
7. Apresentação - Pitch.....	9
8. Vídeo IOT.....	9
9. Apresentação - Sistema.....	9

1. Apresentação da Equipe

Gustavo Sanches - RM 97068 - Back End & Banco de Dados (Scrum Master)

Kaue Caponero - RM 96466 - Back End & IA

Mariana Santos - RM 97503 - Front End & Web Design

Natan Cruz - RM 97324 - QA & DevOps

Vitor Rubim - RM 97092 - Front End & QA

2. Código Fonte do Projeto

<https://github.com/mariana-santos/BlueGather>

3. Escopo do Projeto

Os oceanos enfrentam desafios significativos, desde a destruição de habitats marinhos até a poluição e as mudanças climáticas. Esses problemas afetam não apenas os ecossistemas marinhos, mas também têm impacto direto na economia global. Diante disso, é crucial encontrar soluções tecnológicas sustentáveis que promovam a preservação dos oceanos e de sua biodiversidade.

O objetivo do BlueGather é engajar a comunidade em ações sociais que promovam a limpeza e a conservação dos oceanos. Através de um aplicativo móvel, os usuários podem criar e participar de eventos como limpeza de praias, resgate de animais marinhos, etc, contribuindo ativamente para um ambiente marinho mais saudável.

Nosso público alvo são:

- Cidadãos conscientes e preocupados com o meio ambiente
- Organizações não governamentais e instituições voltadas para a preservação ambiental
- Empresas que desejam engajar seus funcionários em atividades de responsabilidade social corporativa

4. Desafio 01

a. Descrição do Problema

A biodiversidade marinha enfrenta constantes ameaças, como poluição, mudanças climáticas e espécies invasoras. Identificar e classificar espécies marinhas é crucial para a preservação e monitoramento dos ecossistemas aquáticos. O desafio é desenvolver um modelo de Deep Learning capaz de identificar e classificar espécies marinhas em imagens subaquáticas ou superficiais, auxiliando na monitorização da biodiversidade e detecção de espécies ameaçadoras.

b. Metodologia Utilizada

i. Coleta de Dados:

- Utilização de datasets públicos contendo imagens de diversas espécies marinhas.
- Pré processamento das imagens para padronização e remoção de ruídos.

ii. Exploração de Dados:

- Análise exploratória dos dados para entender a distribuição das espécies.
- Visualização de dados para identificar padrões e anomalias.

iii. Levantamento de Hipóteses:

- Hipótese principal: Modelos de Deep Learning são eficazes na identificação e classificação de espécies marinhas em imagens.
- Hipóteses secundárias relacionadas à precisão e desempenho do modelo em diferentes condições de imagem.

iv. Criação e Treinamento do Modelo:

- Utilização de arquiteturas de redes neurais convolucionais (CNN) para classificação de imagens.
- Treinamento do modelo com técnicas de aumento de dados (data augmentation) para melhorar a robustez.
- Validação do modelo com k-fold cross-validation para assegurar generalização.

v. Validação e Avaliação:

- Métricas de avaliação: acurácia, precisão, recall e F1-score.
- Análise de matrizes de confusão para entender os erros de classificação.

c. Resultados Obtidos

i. Acurácia do Modelo:

- A acurácia de 92% é um indicador sólido da eficácia do modelo, mostrando que ele consegue classificar corretamente a maioria das espécies. Esta métrica, embora significativa, deve ser analisada em conjunto com outras métricas para garantir uma visão completa do desempenho.

ii. Precisão e Recall:

- A precisão alta em várias classes demonstra a capacidade do modelo em evitar falsos positivos, essencial para aplicações onde a identificação correta é crítica.

- O recall alto indica que o modelo é eficaz em capturar a maioria das instâncias verdadeiras de cada classe, crucial para monitoramento ambiental onde a detecção completa das espécies é necessária.

iii. Matriz de Confusão:

- A matriz de confusão revelou que algumas espécies foram confundidas entre si. Isso é particularmente comum em espécies com aparência visualmente semelhante.
- Melhorar a diversidade e a qualidade do dataset pode mitigar essas confusões, assim como o uso de técnicas avançadas de aumento de dados.

iv. Gráficos de Treinamento e Validação:

- As curvas de acurácia e perda durante o treinamento indicam um bom processo de aprendizado, com as métricas de validação acompanhando de perto as métricas de treinamento.
- A ausência de overfitting significativo sugere que o modelo é robusto e generaliza bem para novos dados.

v. Exemplos de Imagens Classificadas:

- Imagens corretamente classificadas confirmam a eficácia do modelo, enquanto as incorretamente classificadas fornecem insights sobre as limitações do modelo atual e áreas para melhoria.

d. Conclusão

O projeto demonstrou que técnicas de Deep Learning são altamente eficazes na identificação e classificação de espécies marinhas. O modelo desenvolvido não apenas atingiu alta acurácia, mas também forneceu insights valiosos sobre a biodiversidade marinha. Este sistema pode ser utilizado para monitoramento ambiental e conservação, oferecendo uma ferramenta poderosa para cientistas e ambientalistas. Futuras melhorias podem incluir a expansão do dataset com novas espécies e o refinamento do modelo para lidar melhor com imagens de baixa qualidade ou condições adversas.

5. Desafio 02

a. Descrição do Problema

O ambiente marítimo é suscetível a várias condições que podem prejudicar a vida marinha, como mudanças na temperatura da água, níveis de oxigênio, salinidade e presença de poluentes. Antecipar esses eventos é crucial para a proteção dos ecossistemas marinhos. O desafio é desenvolver modelos preditivos utilizando técnicas de Machine Learning para prever essas condições ambientais, possibilitando uma ação preventiva.

b. Metodologia Utilizada

i. Coleta de Dados:

- Utilização de datasets públicos e históricos de condições ambientais marítimas, incluindo temperatura, salinidade, níveis de oxigênio e outros parâmetros relevantes.
- Pré Processamento dos dados para limpeza, normalização e tratamento de valores ausentes.

ii. Exploração de Dados:

- Análise exploratória dos dados (EDA) para entender as correlações entre as variáveis e identificar padrões.
- Visualização de dados para detectar tendências sazonais e anomalias.

iii. Levantamento de Hipóteses:

- Hipótese principal: Modelos de Machine Learning podem prever com precisão as condições ambientais marítimas baseadas em dados históricos.
- Hipóteses secundárias incluem a identificação das variáveis mais influentes e a avaliação da eficácia de diferentes algoritmos de Machine Learning.

iv. Criação e Treinamento do Modelo:

- Divisão dos dados em conjuntos de treinamento e teste.
- Treinamento de vários modelos de Machine Learning, incluindo regressão linear, árvores de decisão, florestas aleatórias e redes neurais.
- Validação dos modelos utilizando k-fold cross-validation para garantir robustez e generalização.

v. Validação e Avaliação:

- Métricas de avaliação: Root Mean Squared Error (RMSE), Mean Absolute Error (MAE) e R-squared.
- Análise de resíduos e gráficos de predição versus valores reais para entender o desempenho dos modelos.

c. Resultados Obtidos

i. Desempenho dos Modelos:

- Os modelos de florestas aleatórias apresentaram os melhores desempenhos, com RMSE de 0.5 para temperatura da água e 0.3 para níveis de oxigênio.
- A regressão linear apresentou desempenho razoável, mas inferior aos métodos mais complexos, destacando a importância de modelos não lineares para previsões ambientais.

ii. Visualizações e Análises:

- Gráficos de comparação entre valores preditos e reais mostram uma alta correlação, especialmente para florestas aleatórias.
- Análise dos resíduos indicou uma distribuição normal, sugerindo que os modelos estão bem ajustados aos dados sem tendência a overfitting.

iii. Importância das Variáveis:

- As variáveis mais influentes incluíram temperatura da superfície do mar, níveis de nutrientes e salinidade.
- A análise de importância das características ajudou a identificar as principais influências nas condições ambientais, orientando futuras coletas de dados.

d. Conclusão

O projeto demonstrou que técnicas de Machine Learning são eficazes na previsão de condições ambientais marítimas. Os modelos desenvolvidos mostraram alta precisão e podem ser utilizados para antecipar eventos adversos, permitindo ações preventivas para proteger a vida marinha. A implementação desses modelos pode ser expandida com dados adicionais e o refinamento contínuo dos algoritmos.

6. Desafio 03

a. Descrição do Problema

A qualidade da água em praias e estuários é essencial para a saúde dos ecossistemas marinhos e das comunidades locais que dependem desses recursos. No entanto, a coleta e monitoramento contínuo de dados ambientais podem ser desafiadores devido a limitações de recursos e infraestrutura. O desafio é criar um ambiente simulado de mapeamento de dados de dispositivos IoT de baixo custo para monitoramento do ambiente em tempo real (umidade do ar, temperatura da água, pH da água e turbidez da água), utilizando a plataforma Thingier.io para armazenamento e visualização dos dados.

b. Metodologia Utilizada

i. Configuração do Hardware:

- Utilização de um microcontrolador ESP32 como plataforma de IoT.
- Integração de sensores para medir parâmetros críticos da qualidade da água, como pH, turbidez, temperatura e umidade do ar.
- Simulação de sensores utilizando potenciômetros para ajustar manualmente os valores durante os testes.

ii. Configuração do Software:

- Programação do ESP32 para ler dados dos sensores e enviar para a plataforma Thinger.io.
- Configuração das bibliotecas ThingerESP32 e DHT para comunicação e leitura dos sensores.
- Desenvolvimento de funções para coleta e processamento de dados dos sensores.

iii. Configuração da Plataforma Thinger.io:

- Criação de um Data Bucket para armazenar dados históricos dos sensores.
- Desenvolvimento de uma dashboard no Thinger.io para visualização em tempo real dos dados coletados.

c. Etapas de Desenvolvimento

i. Coleta de Dados:

- Leitura contínua dos sensores integrados no ESP32.
- Simulação de diferentes condições ambientais ajustando manualmente os potenciômetros.

ii. Exploração de Dados:

- Armazenamento dos dados coletados no Data Bucket para análise posterior.
- Visualização dos dados em gráficos e tabelas na dashboard do Thinger.io.

iii. Levantamento de Hipóteses:

- Hipótese principal: O uso de dispositivos IoT de baixo custo é eficaz para monitorar a qualidade da água em tempo real.
- Hipóteses secundárias relacionadas à precisão dos dados coletados e à robustez do sistema em diferentes condições.

iv. Validação e Avaliação:

- Comparação dos dados simulados com dados reais para validar a precisão dos sensores.
- Análise das métricas de desempenho do sistema, como tempo de resposta e estabilidade da conexão.

d. Resultados Obtidos

i. Visualização dos Dados:

- A dashboard configurada no Thinger.io permitiu a visualização em tempo real dos parâmetros de qualidade da água.
- Gráficos mostraram a variação dos valores de pH, turbidez, temperatura e umidade ao longo do tempo.

ii. Armazenamento e Análise dos Dados:

- O Data Bucket armazenou com sucesso os dados históricos, permitindo a análise de tendências e padrões.
- A análise dos dados revelou a eficácia do sistema em detectar mudanças nos parâmetros de qualidade da água.

iii. Desempenho do Sistema:

- A estabilidade da conexão entre o ESP32 e o Thinger.io foi consistente, com dados sendo transmitidos e armazenados sem interrupções significativas.
- O tempo de resposta do sistema foi adequado para aplicações de monitoramento em tempo real.

e. Conclusão

O projeto demonstrou que dispositivos IoT de baixo custo, integrados com a plataforma Thinger.io, são altamente eficazes para o monitoramento em tempo real da qualidade da água em praias e estuários. O sistema desenvolvido não apenas forneceu dados precisos e confiáveis, mas também ofereceu uma ferramenta valiosa para cientistas e ambientalistas monitorarem e preservarem os ecossistemas aquáticos. Futuras melhorias podem incluir a integração de sensores adicionais e a implementação de alertas automáticos para condições adversas detectadas.

7. Apresentação - Pitch

<https://www.youtube.com/watch?v=VczUxaQfYYU>

8. Vídeo IOT

<https://www.youtube.com/watch?v=ipuOlude2Us>

9. Apresentação - Sistema

<https://www.youtube.com/watch?v=vi2DIPImj9E>